


흡연 여부 데이터 분석을 통한 건강 인사이트 도출



목차

- 01 프로젝트 개요
- 02 분석 목표
- 03 데이터구조 및 처리
- 04 데이터 시각화
- 05 단변량 & 이변량 분석
- 06 변수 간 상관관계 탐색
- 07 통계적 유의성 검증
- 08 결과 해석
- 09 결론

프로젝트 개요

- 흡연 여부는 건강에 큰 영향을 주지만 직접 조사에는 한계가 있음
- 건강검진 데이터를 활용해 흡연 여부에 따른 건강 지표 차이를 분석

분석 목표

- 흡연자와 비흡연자 간의 건강 지표 차이 분석
- 주요 변수들의 분포, 상관관계, 통계적 유의성 검증
- 시각화를 통한 데이터 인사이트 도출
- 추후 흡연 여부 예측 모델 개발을 위한 기초 분석 기반 마련

데이터 구조 및 처리 - 데이터 구조

- 자료 : 7000개
- Column 개수 : 18개
- Data Type : float64(8개), int64(9개), object(1개)
- 결측치 : 시력, 공복혈당, 혈압, 중성지방에서 140개

#	Column	Non-Null Count	Dtype
0	ID	7000 non-null	object
1	나이	7000 non-null	int64
2	키	7000 non-null	int64
3	몸무게	7000 non-null	int64
4	BMI	7000 non-null	float64
5	시력	6860 non-null	float64
6	총치	7000 non-null	int64
7	공복혈당	6860 non-null	float64
8	혈압	6860 non-null	float64
9	중성지방	6860 non-null	float64
10	혈청 크레아티닌	7000 non-null	float64
11	콜레스테롤	7000 non-null	int64
12	고밀도지단백	7000 non-null	int64
13	저밀도지단백	7000 non-null	int64
14	헤모글로빈	7000 non-null	float64
15	요 단백	7000 non-null	int64
16	간 효소율	7000 non-null	float64
17	label	7000 non-null	int64
Dtype: float64(8), int64(9), object(1)			

데이터 구조 및 처리 - 기초 통계량 및 분포

health_data.describe()

	나이	키 (cm)	몸무게 (kg)	BMI	시력	충치	공복 혈당	혈압	중성 지방	혈청 크레아티닌	콜레스테롤	고밀도 지단백	저밀도 지단백	헤모글로빈	요 단백질	간 효소율
count	7000	7000	7000	7000	6860	7000	6860	6860	6860	7000	7000	7000	7000	7000	7000	7000
mean	43.97	164.78	65.93	24.14	1.01	0.23	99.31	45.56	127.03	0.88	197.28	57.36	115.35	14.63	1.08	1.14
std	12.06	9.17	12.98	3.5	0.43	0.42	21.19	8.83	73.22	0.24	36.31	14.51	41.79	1.54	0.39	0.43
min	20	135	30	14.27	0.1	0	57	14	21	0.1	86	18	1	4.9	1	0.14
25%	35	160	55	21.6	0.8	0	89	40	74	0.8	173	47	92	13.6	1	0.84
50%	40	165	65	23.88	1	0	96	45	107	0.9	195	55	113	14.8	1	1.1
75%	50	170	75	26.12	1.2	0	104	50	161	1	219	66	136	15.7	1	1.38
max	85	190	130	42.45	9.9	1	386	91	399	10	395	157	1340	20.9	5	5.67

데이터 구조 및 처리 - 중복 데이터 처리

```
# 중복 데이터 확인
health_data.duplicated(subset=health_data.columns.difference(['ID'])).sum()

# 중복 데이터 제거
health_data = health_data.drop_duplicates(
    subset=health_data.columns.difference(['ID']),
    keep='first'
).reset_index(drop=True)
```

- 중복 데이터 : 166쌍
- 제거 전 데이터: 7000건
- 제거 후 데이터 : 6834건

데이터 구조 및 처리 - 파생변수 생성

1. BMI 구간 설정

```
bins = [0, 18.5, 23, 25, 30, 35, float("inf")]  
labels = ["저체중", "정상", "비만전단계", "1단계 비만", "2단계 비만", "3단계 비만"]  
health_data["BMI 구간"] = pd.cut(health_data["BMI"], bins, labels=labels, right = False)
```

2. 나이대 구간 설정

```
bins = [20, 30, 40, 50, 60, 70, 80, float("inf")]  
labels = ['20대', '30대', '40대', '50대', '60대', '70대', '70대 초과']  
health_data["나이대"] = pd.cut(health_data["나이"], bins, labels=labels, right = False)
```

데이터 구조 및 처리 - 결측치 대체

- 혈압 → 중앙값 대체
- 시력 → 최빈값 대체
- 나이대별 중성지방 → 그룹 평균
- 공복혈당 → 평균

```
health_data['혈압'] = health_data['혈압'].fillna(health_data['혈압'].median())
health_data['시력'] = health_data['시력'].fillna(health_data['시력'].mode()[0])
health_data['공복 혈당'] = health_data['공복 혈당'].fillna(health_data['공복 혈당'].mean())
health_data['중성 지방'] = health_data['중성 지방'].fillna(health_data.groupby('나이대')['중성 지방'].transform('mean'))
```

데이터 구조 및 처리 - 이상치 처리

- 시력
 - 3.0 초과 값의 값을 None 값으로 변경 후 최빈값으로 대체
- 혈청 크레아티닌
 - 8 초과 값의 값을 None 값으로 변경 후 중앙값으로 대체
- 저밀도 지단백
 - 500 초과 값의 값을 None 값으로 변경 후 나이대별 중앙값으로 대체

이상치 None 값으로 변경

```
health_data.loc[health_data['시력']>3, '시력'] = None
health_data.loc[health_data['혈청 크레아티닌']>8, '혈청 크레아티닌'] = None
health_data.loc[health_data['저밀도지단백']>500, '저밀도지단백'] = None
```



이상치 대체









```
health_data['저밀도지단백'] = (health_data
                                .groupby(by = '나이대')['저밀도지단백']
                                .transform(lambda x : x.fillna(x.median())))









health_data['시력'] = health_data['시력'].fillna(health_data['시력'].mode()[0])
health_data['혈청 크레아티닌'] = health_data['혈청 크레아티닌'].fillna(health_data['혈청 크레아티닌'].median())
```









데이터 구조 및 처리 - 정제 데이터

#	나이	키(cm)	몸무게(kg)	BMI	시력	공복 혈당	혈압	중성 지방	혈청 크레아티닌	콜레스테롤	고밀도지단백	저밀도지단백	헤모글로빈	간 효소율
count	6834	6834	6834	6834	6834	6834	6834	6834	6834	6834	6834	6834	6834	6834
mean	43.99	164.78	65.95	24.15	0.997	99.34	45.56	127.11	0.88	197.29	57.34	114.73	14.63408	1.15
std	12.08	9.19	12.98	3.499	0.29	20.98	8.75	72.53	0.22	36.42	14.46	33.75	1.54	0.43
min	20	135	30	14.27	0.1	57	14	21	0.1	86	18	1	4.9	0.14
25%	35	160	55	21.6	0.8	89	40	74	0.8	173	47	92	13.6	0.84
50%	40	165	65	23.88	1	96	45	108	0.9	195	55	113	14.8	1.1
75%	50	170	75	26.12	1.2	103	50	160	1	219	66	136	15.7	1.38
max	85	190	130	42.45	2	386	91	399	7.4	395	157	307	20.9	5.67




데이터 시각화 -연속형 자료







데이터 시각화 - 범주형 자료



단변량 분석

전체 표본 수
7,000명



6,834명

중복 데이터 : 166건 삭제
결측치 : 140건 대체

이상치 처리

시력 : 최대 9.9 → 입력 오류 또는 이상치

혈청 크레아티닌 : 최대 10 → 신장기능 이상 또는 이상치

저밀도지단백: 190이상의 고위험군 존재 / 최대 1340 → 이상지질혈증 또는 이상치

분포

정규 분포에 가까움 : 키, 나이, 몸무게

우측 치우침 : 저밀도지단백, 공복 혈당, 중성지방, BMI, 혈청 크레아티닌

이변량 분석

개요 및 목적	흡연 여부(label)와 각 건강 지표간의 관계를 통계적으로 탐색	
변수 간 차이	연관성 확인	유의성 검증
흡연 여부 기준 그룹 간 분포 비교	범주형 • 연속형 변수 각각 적합한 검정 적용	p-value + 효과 크기로 실질적 차이 판단

변수 간 상관관계 탐색


주요 인사이트

- 헤모글로빈 : label 상관 최고 ($r = 0.40$)
- 중성지방 : label과 중관 상관 ($r = 0.25$)
- HDL : 음의 상관, 비흡연자 우위

TOP 5

1. 헤모글로빈	0.403
2. 중성지방	0.247
3. 혈청 크레아티닌	0.225
4. 간 효소율	0.182
5. 고밀도지단백	0.179






변수 간 상관관계 Heatmap



주요 변수 후보 선정

순위	변수	상관계수(r)	방향	의학적 근거
1	헤모글로빈	0.403	흡연자↑	흡연 시 흡입되는 일산화탄소(CO)가 헤모글로빈과 결합해 산소운반을 방해하고, 이에 대한 보상 반응으로 적혈구 생성이 높아짐
2	중성 지방	0.247	흡연자↑	흡연이 지질 대사를 방해해 지단백 분해효소 활성을 억제해 중성 지방 수치를 높임
3	혈청 크레아티닌	0.225	흡연자↑	흡연의 혈관 수축 작용으로 인해 사구체 여과율 (GFR)을 저하시키고, 장기적으로 크레아티닌 배출이 감소함
4	간 효소율	0.182	비흡연자↑	교란변수(나이, 음주 습관 등) 가능성 있어 추가 분석 필요
5	고밀도지단백	0.179	비흡연자↑	HDL 합성 효소 활성을 억제해 HDL 수치를 낮춤

흡연 여부에 따른 변수 분포 비교




통계적 유의성 검증

label vs 범주형	label vs 연속형
Chi-squared Test	t-test

카이제곱 검증결과		
변수	p-value	유의
나이대	5.80e-48	✓
BMI 구간	4.37e-22	✓
총치	7.32e-15	✓
요 단백	0.486	✗


t-test 결과		
변수	p-value	유의
헤모글로빈	6.03e-265	✓
중성 지방	2.64e-95	✓
혈청 크레아티닌	5.30e-79	✓
간 효소율	7.18e-52	✓
고밀도지단백	3.12e-50	✓
혈압	0.172	✗
콜레스테롤	0.404	✗

효과 크기 및 결과 해석



Effect Size Summary		
변수	V	해석
나이대	0.186	Weak
BMI 구간	0.127	Weak
총치	0.094	Negligible
V 기준 : < 0.1 Negligible 0.1-0.3 Weak 0.3-0.5 Moderate ≥ 0.5 Strong		

효과 크기 및 결과 해석



Effect Size Summary		
변수	d	해석
헤모글로빈	0.913	Large
중성 지방	0.528	Medium
혈청 크레아티닌	0.478	Medium
간 효소율	0.383	Small
고밀도지단백	0.377	Small
d 기준: < 0.2 Negligible 0.2-0.5 Small 0.5-0.8 Medium > 0.8 Large		

결론 - 핵심 발견 요약

흡연 여부와 가장 강하게 연관된 변수

- 헤모글로빈 ($d = 0.913$, Large)
- 중성 지방($d = -0.528$, Medium)
- 혈청 크레아티닌($d = -0.478$, Medium)

통계적으로 유의하지 않은 변수

- 혈압, 콜레스테롤, 요단백 -> 흡연과 관련성 낮음

결론 - 분석의 한계

- 관찰 데이터로 연관성 확인 가능, 인과관계 증명 불가.
- 나이, 성별 등 교란변수 미통제.
- 간 효소율 방향성은 추가 분석 필요.

감사합니다