

스트레스 지수 예측 해커톤

2 거 스트레스조



김지현

박빛샘

안상
균

목차

01

프로젝트 소개

배경 및 목표, 팀 역할, 협업 방식, 데이터 구성, 평가지표

02

데이터 분석 및 전처리

변수 분석, 결측치 처리, 데이터 누수 방지

03

모델링 전략

파생변수, ExtraTrees 모델, 분위수 예측

04

성능 개선 과정

버전 별 실험 & MAE 변화

05

최종 결과 및 결론

Public MAE & 핵심 인사이트



01 프로젝트 소개 - 배경 및 목표

누구나 경험하는 스트레스

스트레스는 일상에서 흔히
경험하며
신체적 · 정신적 건강에 영향을
줍니다.




건강 데이터 기반 분석

신체 정보와 생활 습관을
활용하면
스트레스 수준을 객관적으로
분석할 수 있습니다.



AI 스트레스 점수 예측

개인의 건강 · 생활 데이터를
기반으로
0~1 범위의 스트레스 점수를
예측합니다.



개인별 스트레스 수준을 예측하여 예방 중심의 건강 관리를
지원합니다.



01 프로젝트 소개 - 팀 역할 및 협업 방식



Notion

일정 공유 및 링크 공유,
아이디어 및 모델 성능 기록



GitHub

코드 및 작업 파일 공유
실험 코드 · 설정 관리
로컬 실험 결과를 저장소에 기록



ZEP

팀원별 실험 결과 비교
효과가 확인된 개선안 공유
다음 실험 방향 결정

가설 공유 ⇒ 개별 실험 ⇒ 결과 비교 ⇒ 개선안 축적



김지현 / 팀장

- 프로젝트 일정 조율
- 파생변수 · 모델 개선



박빛샘

- 발표 자료 제작
- ExtraTrees · 분위수 조정



안상균

- GitHub & Notion 관리
- 대안 모델 · 튜닝

Notion 과 ZEP 으로 소통하고 , GitHub 저장소를 통해 코드와 실험 결과를
공유했습니다 .

01 프로젝트 소개 - 데이터 구성 및 평가 지표

Train Data

- 3,000 건 X 18 개 컬럼
- stress_score 포함

—	●	●	♥
—	●	●	♥
—	●	●	♥
—	●	●	♥
—	●	●	♥


Test Data

- 3,000 건 X 17 개 컬럼
- stress_score 예측 대상

—	●	●
—	●	●
—	●	●
—	●	●
—	●	●

평가 지표 : MAE

- 실제 점수와 예측 점수 차이의 절댓값 평균
- 값이 낮을수록 성능이 우수



개인의 신체 · 생활 정보를 활용하여 **0-1** 범위의 스트레스 점수를 예측합니다.

02 데이터 분석 및 전처리

데이터 구성

	신체 정보	건강 정보	생활 습관	범주형 변수	수치형 변수
1	심박수	혈당	활동량	성별	키
2	혈압	콜레스테롤	근무시간	나이	몸무게
3	골밀도			지역	혈액
4				종교	소득
5				직업	자산
6				가족 구성	주택 가격

- 0 신체 정보 : 키, 몸무게, 혈압, 골밀도 등
- 0 건강 정보 : 혈당, 콜레스테롤 등
- 0 생활 습관 : 활동량, 근무시간 등
- 0 범주형 · 수치형 변수가 함께 존재
- 0 일부 변수에 결측치가 존재

결측치 처리


- 0 수치형 변수 : 중앙값 대체
- 0 범주형 변수 : missing이라는 별도 범주로 대체
- 0 결측 여부를 추가 변수로 생성

	신체 정보	건강 정보	생활 습관	범주형 변수	수치형 변수
1	72	8,100			
2		7,300			
3	68				
4		6,900			
5	74				




	신체 정보	건강 정보	생활 습관	범주형 변수	수치형 변수
1	72	8,100	✓		
2	70	7,300	✓		
3	68	7,000	✓		
4	70	6,900	✓		
5	74	7,000	✓		

범주형 변수 처리




- 0 One-Hot Encoding 적용
- 0 Train 데이터로만 인코더 학습
- 0 Test의 미확인 범주는 무시

데이터 누수 방지




전처리 기준은 Train 데이터로 학습하고, Test 데이터에서는 학습된 기준을 적용하여 예측만 수행함.

03 모델링 전략




파생 변수와 피처 가중치를 적용한 1,200 개 트리의 예측을 51% 분위수로 집계

04 성능 개선 과정



세 가지 개선 전략을 결합하여 Public MAE 0.12827 달성

04 성능 개선 과정 - 제출별 Public MAE 변화



최초 대비 개선

23.95%

0.1686789 → 0.1282777
절대 MAE 0.040401 감소

V7 대비 개선

0.000496

Public 차이는 작지만
V1 은 검증 안정성까지 확인

해석 : 큰 도약은 중요 피쳐 가중 + 중앙값 계열 집계에서 발생했고 , V1 은 51% 분위수로 마지막 미세 개선을 만들었습니다 .

05 최종 결과 및 결론 – 최종 Public MAE



최종 모델

Weighted Quantile
ExtraTrees

Public
MAE
0.1282
7

❖ 점수가 낮을수록 우수함

05 핵심 인사이트

성능을 만든 4 가지 선택

좋은 점수는 하나의 모델보다, 데이터 표현과 검증 기준을 함께 잡은 결과였습니다.

01 건강 데이터를 더 잘 표현

BMI, 혈압 관계, 대사 비율, 결측치 개수로 원본 변수의 의미를 확장했습니다.

02 중요 피처를 더 자주 보게 함

mean_working, BMI, 혈당, 콜레스테롤 등 핵심 지표의 선택 확률을 높였습니다.

03 평균이 아닌 51% 분위수 선택

MAE에 유리한 중앙값 계열 집계로 트리별 예측의 흔들림을 줄였습니다.

04 V1을 기준으로 실험 누적

UNIFIED 리포에서 코드, 설정, 점수, 실험 가설을 같은 형식으로 관리합니다.



Q & A

1

Private Score 도 1 등일까요 ?

확정할 수는 없지만 , V1 은 여러 검증에서 안정적으로 개선됐습니다 .

2

왜 ExtraTrees 를 썼나요 ?

비선형 관계와 변수 상호작용을 강한 무작위성으로 잘 포착했습니다 .

3

왜 평균이 아니라 51% 분위수인가요 ?

MAE 는 중앙값 계열 예측에 유리하고 , 51% 가 검증에서 가장 안정적이었습니다 .

4

데이터 누수는 어떻게 막았나요 ?

결측치 처리와 인코딩 기준은 Train 에서만 학습하고 Test 에는 변환만 적용했습니다 .



핵심 답변 : 좋은 점수보다 재현 가능한 개선 과정이 중요합니다

03 모델링 전략 - Baseline V1

01

행 단위 파생변수

BMI · 맥압 · 평균동맥압 · 혈압
비율 · 대사 비율 · 결측치 개수

02

중요 건강지표 가중

핵심 8 개 피처를 2 회 복제해 분할 후보 선택 확률
강화

03

ExtraTrees 1,200 개

max_features=1 로 트리 다양성을 확보하고
비선형 관계 학습

04

51% 분위수 예측

평균 대신 트리 예측의 51% 분위수를 사용해 MAE 최적화

03 모델링 전략 - 파생변수와 가중 피쳐

01



건강지표 결합

BMI / 맥압 /
평균동맥압
혈압 비율 생성

02



대사 · 결측 신호

콜레스테롤 · 혈당 비율
결측치 개수 활용

03




핵심 피쳐 가중

8 개 핵심 피쳐 × 3 열
분할 선택 확률 강화

원본 건강 데이터를 모델이 이해하기 쉬운 신호로 바꾸고 , 중요한 변수는 더 자주 보게 했습니다 .

03 모델링 전략 - 51% 분위수 예측

평균 대신 트리별 예측 분포의 51% 지점을 최종 예측값으로 사용했습니다.



01 트리별 예측 수집

ExtraTrees 1,200 개가
각기 다른 예측값 생성

02 평균 대신 분위수

극단 예측의 영향을 줄이고
MAE 에 더 맞는 집계 사용

03 51% 지점 선택

중앙값보다 살짝 높은 위치가
검증에서 가장 안정적

실제 구현 : quantile=0.51, clip 0~1, 0.01 단위 반올림 없음

05 최종 결과 및 결론

V1 을 팀 기준 모델로 확정하고 , 이후 실험은 모두 이 기록과 비교합니다 .

Baseline V1

Public MAE

0.1282776667

3 회 제출 중 최고 기록이며 , 최초 제출 대비 약 23.95% 개선했습니다 .

- 01** 핵심 성과 : 중요 건강지표 가중 + 51% 분위수 집계가 마지막 개선을 만들었습니다 .
- 02** 검증 안정성 : 반복 CV 평균 0.147505, 중복 그룹 검증 0.149202 로 관리합니다 .
- 03** 다음 단계 : UNIFIED 리포에서 한 실험 한 가설 원칙으로 개선 후보를 누적합니다 .

결론 : V1 은 제출용 모델이자 , 내일부터의 실험 판단 기준입니다 .




05 향후 운영 - UNIFIED 실험 허브

V1 을 고정 기준으로 두고 , 모든 실험을 같은
형식으로 누적합니다 .

- 01 **Baseline 고정**
V1 코드 · 설정 · 성능을
main 기준으로 보존
- 02 **실험 브랜치**
exp/E001-... 단위로
한 실험 한 가설만 변경
- 03 **기록 · 비교**
OOF · Public · Private 을
registry 에 누적 관리

목표 : 빠른 실험보다 재현 가능한 개선



05 향후 실험 로드맵

V1 을 기준으로 두고 , 한 번에 하나의 가설만 검증합니다 .

Baseline V1 | Public MAE 0.1282776667

01

분위수 미세 조정

0.50~0.52 구간에서 MAE 가 안정적으로 낮아지는지 확인

02

가중 피쳐 재검토

복제 피쳐 수와 대상 변수를 하나씩 바꿔 중요도 효과 검증

03

파생변수 추가 실험

업무 · 대사 · 혈압 계열의 조합 변수를 제한적으로 추가

04

검증 안정성 확인

Seed 42/2026/3407 과 그룹 분할에서 일관된 개선만 제출 후보로 승격

목표 : Public 최적화보다 Private 에서도 버틸 수 있는 안정적 개선



05 운영 원칙 - Private Score 관리

Public 점수는 방향을 보여주지만 , 최종 순위는 **Private** 에서 결정됩니다 .

01 **Public** 만 보고 우열 확정 금지

V7 과 V1 의 차이는 0.00050 수준으로 작아
Private 역전 가능성도 함께 관리합니다 .

02 검증 개선이 있어야 제출 후보

여러 Seed 와 중복 그룹 검증에서 안정적인 개선이
보일 때만 제출합니다 .

03 **V1** 은 고정 기준으로 보존

모든 실험은 V1 대비 변경점 · OOF MAE · 제출
결과를 같은 형식으로 기록합니다 .

좋은 점수보다 재현 가능한 개선을 남깁니다 .

기준 기록 : V1 Public MAE 0.1282776667



실행 · 기록 관리

데이터는 Git 에 올리지 않고 , 코드 · 설정 · 실험 기록만 통합 리포에서 관리합니다 .

01 데이터 분리

CSV 는 로컬 data/ 폴더에만 배치

02 V1 코드 고정

baseline/ 의 기준 코드는 직접 수정하지 않음

03 동일 명령 실행

항상 같은 data-dir 과 output-dir 사용

04 결과만 기록

제출번호 · 파일명 · Public MAE 만 문서화

```
python baseline/v1_weighted_quantile_extratrees.py
--data-dir data --output-dir outputs
```



V1 은 재현 기준점 , 신규 실험은 별도 브랜치에서 진행

05 마무리

V1 을 기준으로
더 안정적인 성능을
만든다

Baseline V1

Public MAE

0.1282776667

코드 · 설정 · 실험 기록을 UNIFIED
리포에 모아
모든 다음 실험을 같은 기준으로 비교합니
다.

다음 단계 : 분위수 · 피쳐 · 검증 안정성 개선



Appendix UNIFIED 리포 구조

내일부터의 실험은
한 곳에서 같은 방식으로
기록합니다 .

- | | | |
|---|---------------------|-------------------------|
| 1 | baseline/ | V1 기준 코드 보존 |
| 2 | configs/ | 모델 설정 기록 |
| 3 | docs/ | Baseline · 실험 규칙 · 리더보드 |
| 4 | experiments/ | E001 실험 문서 · registry |
| 5 | submissions/ | CSV 제외 , 제출 기록만 관리 |

목표 : 좋은 점수와 함께 , 재현 가능한 개선 과정을 남깁니다 .



한 실험을 네 가지 질문으로 남깁니다 .

- 1

가설

무엇을 바꾸면 왜 좋아질 것인가 ?
- 2

V1 대비 변경점

한 번에 핵심 설정 하나만 변경
- 3

검증 결과

Fold·Seed·OOF MAE 를 같은 기준으로 기록
- 4

결론

채택 · 보류 · 폐기와 다음 실험 명시

원칙 : 한 실험 · 한 가설 · 같은 검증 · 명확한 결론

E001 분위수 0.51 → 0.505

exp/E001-change-quantile

가설

중앙값보다 약간 낮은
분위수가 **MAE** 를 줄인다 .

변경점

QUANTILE 만 변경
나머지는 **V1** 고정

V1 CV

0.147505

E001 CV

0.146980

개선

-0.000525

✓ 결론

채택 — 다음 단계에서 **3-Seed** 검증으로 승격

registry.csv

E001	candidate	0.146980	채택	Public	미제출
------	-----------	----------	----	--------	-----

제출은 점수가 아니라 재현 가능한 기록까지 남깁니다 .

Before Submit

- ✓

데이터 누수 확인

Test 통계 · 타깃 · 순서 사용 금지
- ✓

V1 대비 변경점 명확화

한 실험에서 핵심 가설 하나만
- ✓

검증 결과 기록

Fold·Seed·OOF MAE 저장
- ✓

제출 파일 분리

CSV 는 Git 에 커밋하지 않기
- ✓

리더보드 업데이트

제출번호 · 시각 ·Public 만 기록

제출 후에는 결과보다 먼저 실험 문서를 완성합니다 .



발표 흐름은 세 문장으로 정리합니다 .

- 1 건강 · 생활 데이터를
스트레스 점수 예측 문제로 정의했습니다 .
- 2 V1 은 ExtraTrees 1,200 개와
51% 분위수 집계로 최고 Public MAE 를 기록했습니다 .
- 3 이제 모든 실험은 UNIFIED 리포에서
V1 과 비교하며 재현 가능하게 관리합니다 .

마무리 : 좋은 모델은 점수와 설명 , 기록이 함께 남아야 합니다 .



V1 을 고정하고 가설 하나씩 검증합니다 .

E001	분위수 미세 조정	0.505 · 0.515 비교
E002	중요 피쳐 복제 수	1 회 · 2 회 · 3 회 비교
E003	결측치 신호 강화	missing_count 계열 추가
E004	중복 그룹 검증	Private 안정성 점검
E005	후처리 검토	clip 외 반올림은 보류

승격 기준 : 3-Seed 평균과 그룹 검증이 모두 V1 보다 좋아야 합니다 .



좋아 보이는 실험이 아니라 검증을 통과한 실험만 올립니다 .

- 1

빠른 검증

Seed 42 단일 5-Fold 에서 V1 보다 나은가
- 2

반복 검증

Seed 42 · 2026 · 3407 평균이 개선되는가
- 3

그룹 검증

중복 표본 그룹 분할에서도 유지되는가
- 4

제출 후보

변경 이유와 위험을 설명할 수 있는가

기준 : **Public** 점수보다 **Train** 검증의 일관성을 우선합니다 .

